

# Detalhamento do Modelo de Machine Learning

Desafio Integrador - Engenharia de Software 5B

Luan Ribeiro, Matheus Grochovski e Priscila Camargo

O sistema utiliza o algoritmo Random Forest (Floresta Aleatória), implementado nativamente em TypeScript, para realizar análises preditivas relacionadas a: Previsão de risco de churn (abandono de clientes) e Identificação de propensão de compra (upselling).

O modelo foi desenvolvido sem dependência de bibliotecas externas de Machine Learning, permitindo total transparência sobre seu funcionamento e adequação aos requisitos acadêmicos.

## Arquitetura Geral do Modelo

O fluxo de processamento ocorre em seis etapas:

Clientes + Pedidos - Extração de Features - Tratamento de Dados (Duplicados + Outliers) - Normalização Min-Max - Treinamento Random Forest - Predição (Churn e Compra)

## Engenharia de Features

O modelo não utiliza diretamente os registros brutos do banco. Primeiramente são geradas variáveis analíticas (features) que representam o comportamento do cliente.

## Variáveis Utilizadas

| Feature           | Descrição                        |
|-------------------|----------------------------------|
| totalGasto        | Valor total gasto pelo cliente   |
| frequenciaCompras | Quantidade de compras concluídas |
| recenciaDias      | Dias desde a última compra       |

|                         |                                             |
|-------------------------|---------------------------------------------|
| ticketMedio             | Valor médio por pedido                      |
| taxaCancelamentoPedidos | Percentual de pedidos cancelados            |
| itensDiferentes         | Quantidade de produtos distintos adquiridos |

Essas informações são calculadas pela função: `extrairFeaturesDosClientes()`

Exemplo:

Cliente:

- 5 compras
- R\$ 10.000 gastos
- última compra há 15 dias
- 0 cancelamentos

totalGasto = 10000 - frequenciaCompras = 5 - recenciaDias = 15 - ticketMedio = 2000 -  
taxaCancelamentoPedidos = 0 - itensDiferentes = 4

## Tratamento de Dados

Antes do treinamento são executadas etapas de limpeza dos dados.

### Remoção de Duplicidades

Clientes duplicados são identificados através do e-mail.

Método: `tratarRegistrosDuplicados()`

Processo: Email normalizado - Verifica existência - Mantém apenas um registro

Objetivo:

- Evitar duplicidade cadastral;
- Evitar distorção estatística.

## Tratamento de Outliers

O sistema utiliza o método estatístico IQR (Interquartile Range).

Função: tratarOutliersFeatures()

Fórmula utilizada:  $IQR = Q3 - Q1$

Limite Inferior =  $Q1 - 1.5 \times IQR$

Limite Superior =  $Q3 + 1.5 \times IQR$

Valores extremos não são removidos. O sistema utiliza **clipping**, limitando os valores aos limites calculados.

Exemplo:

Total gasto = R\$ 500.000

Limite superior = R\$ 80.000

Valor utilizado = R\$ 80.000

Benefício: Reduz distorções no treinamento.

## Normalização dos Dados

Após a limpeza é aplicada normalização Min-Max. Funções: `treinarEscaladorMinMax()` e `aplicarEscaladorMinMax()` fórmula:  $x' = \frac{x - \min}{\max - \min}$

Todos os atributos passam a variar entre 0 e 1, sendo 0 menor valor e 1 o maior valor.

Exemplo:

| Valor Original | Valor Normalizado |
|----------------|-------------------|
| 1000           | 0.10              |

|       |      |
|-------|------|
| 5000  | 0.50 |
| 10000 | 1.00 |

Benefício: Todas as variáveis passam a ter a mesma escala.

### Estrutura da Árvore de Decisão

Cada árvore é construída utilizando:

- Impureza de Gini;
- Divisões binárias;
- Profundidade máxima configurável.

Classe: NoDecisao Cada nó possui: feature, limite, esquerdo, direito, valorFolha

Exemplo:

Recência > 90 dias? Sim - Churn Alto. Não - churn baixo.

### Critério de Divisão

A escolha da melhor divisão utiliza a Impureza de Gini.

Fórmula:  $Gini = 1 - (p_1^2 + p_0^2)$

Onde:  $p_1$  = proporção da classe positiva e  $p_0$  = proporção da classe negativa.

Quanto menor o Gini melhor separação, maior pureza e maior qualidade da árvore.

### Random Forest

O sistema utiliza um conjunto de árvores de decisão. Classe: RandomForest

| Parâmetro | Valor |
|-----------|-------|
|-----------|-------|

|                 |   |
|-----------------|---|
| maxProfundidade | 7 |
| maxProfundidade | 4 |

```

constructor(

    private numArvores = 7,

    private maxProfundidade = 4

)

```

### **Bootstrap Sampling**

Cada árvore recebe uma amostra aleatória dos dados.

Método: bootstrapSample()

### **Treinamento**

O treinamento ocorre em duas etapas.

### **Churn**

Árvores treinadas para prever:

Cliente abandonará? Saída: 0 = Não 1 = Sim

### **Propensão de Compra**

Árvores treinadas para prever: Cliente tem potencial para comprar novamente?

Saída: 0 = Baixa Propensão e 1 = Alta Propensão

### **Dados de Calibração**

Como a aplicação pode iniciar com poucos registros reais, o modelo gera dados sintéticos para treinamento inicial.

Perfis simulados:

### **Alto Churn**

- Poucas compras;
- Muito tempo sem comprar;
- Muitos cancelamentos.

### **Baixo Churn**

- Compras frequentes;
- Alto gasto;
- Baixa taxa de cancelamento.

### **Perfil Intermediário**

- Comportamento moderado.

Isso garante previsões estáveis mesmo com bases pequenas.

### **Processo de Predição**

Quando um cliente é analisado:

Cliente - Extração de Features - Normalização - Passagem pelas 7 árvores - Coleta dos votos - Média dos votos - Score Final

### **Score de Churn**

0 a 100%

Exemplo: 72%

Significa: Alta probabilidade de abandono.

### **Score de Compra**

0 a 100%

Exemplo: 83%

Significa: Alta chance de nova compra.

### Classificação Final

O sistema transforma os scores em categorias de negócio.

| Faixa       | Classificação |
|-------------|---------------|
| > 65% churn | Alto Risco    |
| 35% a 65%   | Médio Risco   |
| < 35%       | Fidelizado    |
| Sem compras | Inativo       |

### Explainable AI (XAI)

Além da previsão, o sistema gera explicações automáticas.

Exemplos: "Inatividade prolongada (145 dias sem comprar)", "Elevada taxa de cancelamento (60%)", "Excelente volume acumulado de compras". Essa funcionalidade aumenta a interpretabilidade do modelo e auxilia a tomada de decisão gerencial.

### Conclusão

O modelo implementado consiste em uma **Random Forest composta por 7 Árvores de Decisão**, treinadas a partir de dados tratados, normalizados e enriquecidos por engenharia de features. O sistema é capaz de prever risco de churn e potencial de compra, fornecendo indicadores quantitativos e explicações interpretáveis para apoiar decisões estratégicas de retenção e crescimento de receita.

